

Auditoria de medios fallidos “ News Lake

Ethos PR Intelligence / PressClipping Â· Rol B (programador adicional) Â· 2 de septiembre de 2026

Alcance: auditar, clasificar y proponer fuentes publicas conservadoras. No se escribio en Supabase, no se tocaron clientes, Sheets ni keywords, y no hay commit.

Clase A/B/C/D/E segun README_PARALELO_MEDIOS_PRESSCLIPPING. C* = feed/sitemap reciente viable; candidato a A/B si el enrich da cuerpo completo. A no se confirma hasta crawl+enrich autorizado.

A) Medios revisados

Los 25 IDs existen en la tabla medios de Supabase (todos activo=true). 22 fallidos de oleada + 3 excluidos: MED-0109 Canal 8 BCS, MED-0114 Radio UDG, MED-0191 La Silla Rota.

B-E) Tabla de clasificacion (provisional)

medio_id	medio	estado actual	causa	fuentes propuestas	clase	accion
MED-0103	El Peninsular Digital	sin_fuente	sitemap.xml es indice Yoast de archivo 2010; crawl solo ve los primeros 20 subs	https://peninsulardigital.com/post-sitemap100.xml (326 notas/30d, ultima hoy)	C*	cambiar sitemap
MED-0104	Cabo Mil Noticias	error	sitemap 404; /feed/ y WP 404; homepage si responde	ninguna publica	E	no reparar
MED-0105	Radar Politico BCS	error	fetch failed en sitemap; ultimo WP post-sitemap si vive	https://www.radarpolitico.com.mx/wp-sitemap-posts-post-45.xml (254/30d)	C*	cambiar sitemap
MED-0110	Diario El Zalate	error	NXDOMAIN: el dominio no existe	-	E	descartar
MED-0115	DK 1250	error	sitemap fetch failed	https://dk1250.mx/feed (12/12 hoy)	C*	poner RSS
MED-0117	Cronica Jalisco	error	DNS ok, timeout persistente en todas las rutas	-	E	no viable ahora
MED-0099	BCS Noticias	error	sitemap 415 en oleada (WAF); en local el indice si abre	https://www.bcsnoticias.mx/feed/ (30/30 recientes)	C*	cambiar a RSS
MED-0107	Diario Humano	error	sitemap 415 en oleada	https://diariohumano.com.mx/post-sitemap21.xml (119/119 hoy)	C*	cambiar sitemap
MED-0123	CPS Noticias	error	NXDOMAIN	-	E	descartar
MED-0125	Vallarta Uno	error	sitemap 404; homepage si; sin RSS/WP	ninguna publica	E	no reparar
MED-0126	Noticias PV	error	sitemap 404	https://noticiaspv.com.mx/feed (10/10)	C*	poner RSS

MED-0127	Semanario Laguna	error	sitemap 404	https://semanariola guna.com/rss (50/50)	C*	poner RSS
MED-0128	Pagina Que Si Se Lee	sin_fuente	todas las rutas devuelven HTML (SPA)	ninguna publica	E	no reparar
MED-0132	Zapotlan Noticias	error	NXDOMAIN	-	E	descartar
MED-0133	Diario Regional de Zapotlan	error	NXDOMAIN	-	E	descartar
MED-0137	Lagos Noticias	error	NXDOMAIN	-	E	descartar
MED-0139	Mi Region Jalisco	error	NXDOMAIN	-	E	descartar
MED-0140	Ameca Noticias	error	NXDOMAIN	-	E	descartar
MED-0141	Colotlan Noticias	error	NXDOMAIN	-	E	descartar
MED-0143	Arandas Noticias	error	NXDOMAIN	-	E	descartar
MED-0144	La Voz del Norte Jalisco	error	DNS ok, fetch failed	-	E	no viable ahora
MED-0121	Vallarta Opina	error	DNS ok, fetch failed	-	E	no viable ahora
MED-0109	Canal 8 BCS	excluido	metodo=HTML sin rss/sitemap: News Lake no lo selecciona	https://iert.bcs.gob. mx/feed (10/10; IERT, no solo Canal 8)	C*	poner RSS
MED-0114	Radio Universidad de Guadalajara	excluido	metodo=HTML, url_base /radio- udeg sin feed	https://udgtv.com/f eed/ (30/30; UDG TV completo)	C*	poner RSS
MED-0191	La Silla Rota	excluido	metodo=DIRECT; News Lake no llama el extractor DIRECT	https://lasillarota.co m/sitemaps/news.x ml (295/295 hoy)	C*	poner SITEMAP

F) Archivos modificados (sin commit)

- scripts/repair-failed-sources-batch.ts â€” 10 patches, --dry por defecto
- test/repair-failed-sources-batch.test.ts
- package.json â€” script repair-failed-sources-batch

Temporales en tmp/ (no versionar): inventario y probes.

G) Comandos ejecutados

- SELECT de los 25 IDs en Supabase
- audit-media-sources --output=csv --dry-run --include-inactive (sin --update-db, sin Sheet)
- Probe extra: /wp-sitemap.xml, /wp-sitemap-posts-post-1.xml, /wp-json/wp/v2/posts, /feed/
- DNS de hosts fetch failed
- npm run repair-failed-sources-batch -- --dry (solo lectura; 0 writes)
- npm run typecheck
- npm test

H) Typecheck

tsc --noEmit: OK.

I) Tests

- Nuevos: 7/7 OK
- Suite: 1616 passed, 1 failed

El fallo no esta relacionado con este lote: test/patron-no-pc-production-capture.test.ts espera un string del workflow de Patron. No se toco (fuera del rol B).

J) Dry-run por medio

El dry-run de captura (news-lake:capture) no se corrio: el catalogo en DB sigue con las URLs rotas. Hay que aplicar el update (con autorizacion) y despues probar. El dry-run del script de reparacion mostro el plan de 10 medios y no escribio nada.

K) Real controlado

No autorizado. No se corrio.

L) Riesgos

- sync-sheets puede revertir un update de Supabase si 01_Medios no se alinea (eso es Operacion).
- MED-0103 / 0105 / 0107 apuntan al ultimo post-sitemap de Yoast/WP. Cuando abran el 101 / 46 / 22, habra que subir el numero. No se usa el indice: el crawler solo baja 20 subs y se quedaria en archivo viejo.
- MED-0099 y 0107 dieron 415 desde GitHub Actions; el RSS/sub-sitemap se probó desde IP local. Puede fallar otra vez en Actions.
- MED-0109 y 0114 amplian cobertura (IERT / UDG TV), no son el medio puro del nombre.
- 9 dominios muertos (NXDOMAIN): no hay scrape que los recupere.
- No se crearon extractores DIRECT ni se toco news-lake-capture.ts.

M) GO / NO-GO

GO para aplicar (uno por uno, cuando se autorice)

Primero RSS limpios (alta confianza): MED-0115, MED-0126, MED-0127, MED-0099. Luego sitemaps: MED-0103, MED-0105, MED-0107, MED-0191. Luego exclusiones HTML: MED-0109, MED-0114.

Tras cada apply, dry-run de captura:

```
npm run news-lake:capture -- --dry-run --medio-ids=MED-XXXX --max-medios=1 --max-notas=3 --enrich-limit=20 --window-days=30 --chunk-size=1
```

Real (--no-dry-run o Actions dry_run=false) solo si ese dry-run entra (dirigido:true, total_seleccionados:1).

NO-GO reparacion

Los 15 medios clase E. Documentar y seguir. No hay fuente publica conservadora viable.

Para aplicar un solo medio autorizado:

```
npm run repair-failed-sources-batch -- --apply --only=MED-0115
```

Hasta entonces el default del script sigue siendo --dry.

Resumen operativo

10 medios con fuente publica propuesta (GO). 15 medios clase E (NO-GO). Supabase no modificado. Sheets no tocado. Sin commit.