

Informe para Juan “ News Lake / medios

Ethos PR Intelligence | 2 de septiembre de 2026 | Rol B (programador adicional / Cursor) para Operacion

Este documento resume todas las pruebas del 2 de septiembre, lo que ya quedo aplicado en Supabase, y los pasos que debes seguir para no perder el arreglo y continuar (oleada, Mery, paywall).

1. Contexto y alcance

PressClipping externo ya no es fiable. Ethos News Lake captura PRIMERO medios y DESPUES detecta keywords por cliente. Las keywords no deciden que se baja.

Rol B (este trabajo): auditar medios fallidos, buscar RSS/sitemap publicos, clasificar A-E, reparar lo viable y probar captura controlada.

NO se toco: clientes, keywords, Patron final, Jumex final, NOTAS ENVIADAS MERYPOZOS, test_pressclipping, alertas, email, WhatsApp, Twilio. NO hay commit. NO se corrio sync-sheets ni export real a Sheet.

Clases: A = captura + cuerpo completo. B = captura + cuerpo parcial. C = solo titulo/RSS (radar). D = paywall/convenio. E = roto o sin fuente publica.

2. Lote 1 “ medios fallidos de oleada + 3 excluidos

Se leyeron 25 IDs en la tabla medios. Se probaron fuentes publicas (sin proxy, sin Playwright, sin bypass de paywall).

2.1 Once fuentes YA aplicadas en Supabase

Script: npm run repair-failed-sources-batch -- --apply. Update 11/11. Si corres sync-sheets sin actualizar 01_Medios, ESTO SE REVIERTE.

medio_id	Medio	Metodo	URL a copiar en 01_Medios
MED-0029	La Jornada	RSS	https://www.jornada.com.mx/rss/edicion.xml
MED-0099	BCS Noticias	RSS	https://www.bcsnoticias.mx/feed/
MED-0103	El Peninsular Digital	SITEMAP	https://peninsulardigital.com/post-sitemap100.xml
MED-0105	Radar Politico BCS	SITEMAP	https://www.radarpolitico.com.mx/wp-sitemap-posts-post-45.xml
MED-0107	Diario Humano	SITEMAP	https://diariohumano.com.mx/post-sitemap21.xml
MED-0109	Canal 8 BCS / IERT	RSS	https://iert.bcs.gob.mx/feed
MED-0114	Radio UDG / UDG TV	RSS	https://udgtv.com/feed/
MED-0115	DK 1250	RSS	https://dk1250.mx/feed
MED-0126	Noticias PV	RSS	https://noticiaspv.com.mx/feed
MED-0127	Semanario Laguna	RSS	https://semanariolaguna.com/rss
MED-0191	La Silla Rota	SITEMAP	https://lasillarota.com/sitemaps/news.xml

Notas: MED-0109 cubre el sitio IERT (no solo Canal 8). MED-0114 cubre UDG TV completo (no solo radio). MED-0103/0105/0107 apuntan al ultimo post-sitemap de Yoast/WP; si abren el 101/46/22 habra que subir el numero.

2.2 No reparados (clase E)

- Sitio vivo sin feed publico: Cabo Mil (MED-0104), Vallarta Uno (MED-0125), Pagina Que Si Se Lee (MED-0128).
- Timeout / fetch failed: Cronica Jalisco (MED-0117), Vallarta Opina (MED-0121), La Voz del Norte Jalisco (MED-0144).
- Dominio muerto (NXDOMAIN): Diario El Zalate, CPS Noticias, Zapotlan Noticias, Diario Regional de Zapotlan, Lagos Noticias, Mi Region Jalisco, Ameca Noticias, Colotlan Noticias, Arandas Noticias.

3. Lote 2 “ nacionales pedidos (Mural, Reforma, Norte, Expansion, Forbes, Financiero, Indigo, Jornada, Animal Politico)

Medio	ID	Hallazgo	Clase	Accion
Expansion	MED-0159	Ya capturaba. RSS expansion.mx/rss OK.	C* operativo	NO TOCAR
Forbes Mx	MED-0145	Ya capturaba. news-sitemap.xml OK.	C* operativo	NO TOCAR
El Financiero	MED-0156	Ya capturaba. RSS elfinanciero.com.mx/rss OK.	C* operativo	NO TOCAR
La Jornada	MED-0029	Sitemap 403 intermitente. RSS /rss/edicion.xml aplicado.	A (tras captura)	Ya en tabla 2.1
Reporte Indigo	MED-0054	403 en feed y sitemaps. MED-0045 GDL inactivo.	E	No reparar. No proxy.
Animal Politico	MED-0032	Homepage si; sitemaps.animalpolitico.com en 503.	E discovery	Reintentar CDN despues.
Reforma	MED-0027	Grupo Reforma. Sitemap lista URLs; cuerpo de pago.	D	Ver seccion 6
Mural	MED-0037	Mismo grupo.	D	Ver seccion 6
El Norte	MED-0046	Mismo grupo (Norte = El Norte, no Punto Norte).	D	Ver seccion 6

4. Resultados de las pruebas (2 sep 2026)

4.1 Auditoria post-apply

Los 11 reparados quedaron READY_KEEP_CURRENT (fuente configurada entrega notas recientes). Forbes, Financiero y Expansion tambien READY. Indigo BLOCKED. Animal Politico DIRECT_EXTRACTION_ONLY. Reforma/Mural/El Norte el auditor los marca "sitemap reparable" “ NO configurar: es paywall (seccion 6).

4.2 Dry-run News Lake

Comando: news-lake:capture --dry-run con los 11 IDs. Resultado: total_seleccionados=11, total_excluidos=0, dirigido=true. No se descargo ni se escribio nada.

4.3 Captura real controlada

Comando: news-lake:capture --no-dry-run --max-notas=3 --enrich-limit=40 --window-days=30 --chunk-size=11. dry_run=false.

- Crawl: 11/11 ok. 33 insertadas. 0 duplicados. 0 errores.
- Enrich: 33 leidas, 30 actualizadas, 3 fallidas (las 3 de Semanario Laguna). conTextoLimpio=30, conCuerpoNota=30.
- Sheets: un 503 transitorio al abrir diagnosticos; no bloqueo la corrida. No se escribio panel de clientes.

ID	Medio	Crawl	Enrich	Clase	Uso
MED-0029	La Jornada	3	3 cuerpo 1.6-4.3k	A	Usar ya
MED-0103	El Peninsular Digital	3	3 cuerpo 1.7-3.9k	A	Usar ya
MED-0105	Radar Politico BCS	3	3 cuerpo	A	Usar ya
MED-0107	Diario Humano	3	3 cuerpo (hasta 12k)	A	Usar ya
MED-0114	UDG TV	3	3 cuerpo	A	Usar ya
MED-0115	DK 1250	3	3 cuerpo corto 343-626	A	Usar ya
MED-0126	Noticias PV	3	3 texto; un cuerpo 130	A	Usar ya
MED-0191	La Silla Rota	3	3 cuerpo	A	Usar ya
MED-0099	BCS Noticias	3	2 cuerpo OK, 1 sin cuerpo	B	Usar con revision
MED-0109	Canal 8 / IERT	3	Paginas de radio, texto corto	B	Usar con revision
MED-0127	Semanario Laguna	3 titulos RSS	3 enrich error	C	Radar. No revertir el RSS.

Typecheck: OK. Tests del script repair-failed-sources-batch: 8/8. Un fallo viejo de Patron en npm test NO es de este lote; no se toco ese workflow.

5. Como proseguir (orden obligatorio)

Paso 1 “ Alinear 01_Medios (CRITICO)

Copia en la Sheet de control las 11 filas de la seccion 2.1 (rss_url o sitemap_url y metodo_extraccion). Si ejecutas npm run sync-sheets sin eso, Sheets pisa Supabase y se pierde la reparacion. News Lake lee Supabase; el workflow news-lake-capture.yml no pide credenciales de Sheets, pero otros flujos si sincronizan.

Paso 2 “ Oleada controlada

Incluye esos 11 en la siguiente oleada (max_notas=5 o 10). Busca en el log: dirigido, insertadas, duplicados, conTextoLimpio, conCuerpoNota, totalErrores. A y B se quedan. Semanario Laguna (C) se deja como radar.

Paso 3 “ Dry-run Mery (solo despues de captura nueva)

gh workflow run client-live-sheet-export.yml con dry_run=true, client_id=CLI-MERY-TEST, tab_prefix=ETHOS_MERY_CLIENT_TEST, sheet_id ya validado. GO solo si hay incremento nuevo relevante y mismatch:false. Si sale igual que el ultimo dry-run (sin incremento), NO-GO: no exportes.

Paso 4 “ Export real

Solo con GO. Solo tabs nuevas ETHOS_*. No tocar Patron final, Jumex final, NOTAS ENVIADAS MERYPOZOS, test_pressclipping. No borrar noticias ni menciones.

Paso 5 “ Resto E

Dominios muertos: documentar y no insistir. Indigo y Animal Politico: reintentar mas adelante, sin proxy. No crear extractores DIRECT en este lote.

Paso 6 “ Commit

Cuando revises el diff: scripts/repair-failed-sources-batch.ts, su test y package.json. Nunca commitear .env, data/, tmp/ ni dumps de medios. Mensaje sugerido: fix(media): repair public feeds for selected sources

6. Reforma, Mural y El Norte (paywall) “ decision para Operacion

Los tres son Grupo Reforma. Existe sitemap_index.xml con miles de URLs; el CUERPO esta detras de suscripcion. Politica del proyecto: D_PAGO_CONVENIO_API. Un solo convenio comercial cubre las tres cabeceras. NO se configuro nada de estos tres en Supabase.

Opciones (elige una; no se mezclan con scrape)

Opcion	Que implica	Sirve a News Lake
A. Convenio / API / feed comercial	Contrato con Grupo Reforma. Pedir feed o API de datos para clipping, no acceso web.	Si, si ellos entregan canal autorizado. VIA CORRECTA.
B. Suscripcion de lector (Plus/digital)	Cuenta para leer el sitio en el navegador.	NO para el crawler. El muro es por articulo. Solo revision humana puntual.
C. Dejarlos en D y no capturar	Seguir con Jornada, Silla Rota, Forbes, Financiero, Expansion, etc.	DEFAULT DE HOY. El lake ya opera sin ellos.
D. Scrape, proxy o cuenta + robot	Saltar el paywall.	PROHIBIDO. Fuera de politica y fragil.

Criterio para A vs C: cuantas menciones de clientes salen SOLO en Reforma/Mural/El Norte y no en el resto del lake. Si el hueco es chico, quedate en C. Si Patron/Jumex/Mery dependen de esas tres, cotiza UN convenio de grupo (opcion A). Nadie ha contactado a comercial: no hay precio ni confirmacion de que el feed exista.

NO pongas sitemap_index.xml de Reforma/Mural/El Norte en 01_Medios. El auditor automatico lo marca reparable; no es cuerpo publico.

7. Resumen GO / NO-GO

- GO tecnico: 11 medios mas en News Lake (8 A, 2 B, 1 C). Captura de prueba 33 notas, 0 errores de crawl.
- GO operativo pendiente: alinear 01_Medios (paso 1). Sin eso el arreglo es fragil.
- GO Mery: solo tras dry-run con incremento. El dry-run previo sin incremento fue NO-GO; no asumas que 33 notas nuevas = menciones de Mery.
- NO-GO: paywall (D), E muertos, Indigo 403, Animal Politico 503, scrape/proxy.

Siguiente accion tuya: actualizar 01_Medios con la tabla 2.1 y pegar este informe a ChatGPT/operacion si necesitas el comando exacto de la siguiente oleada.